

沃顿高中数据科学竞赛 2026 (WHSDSC)
第一阶段：冰球数据分析报告

加时赛感知 Bradley-Terry 模型与校准逻辑回归

Team TheIsoLab

工具：Python (pandas, scipy, matplotlib) · AI 协作：Claude + Gemini + Codex

2026 年 2 月

Contents

1 项目概述 2

1.1 竞赛背景 2

1.2 核心思路 2

2 数据处理流程 2

2.1 原始数据概况 2

2.2 处理流程图 2

2.3 关键预处理步骤 3

2.4 特征工程 3

3 核心模型：加时赛感知 **Bradley-Terry** 4

3.1 为什么选择 Bradley-Terry? 4

3.2 加时赛问题 4

3.3 迭代最大似然算法 5

4 胜率预测：校准逻辑回归 6

4.1 模型公式 6

4.2 5 折交叉验证方案 6

4.3 评估结果 6

4.4 概率校准 6

5 集成实力排名 7

5.1 综合评分构造 7

5.2 权重鲁棒性 7

5.3 Top 10 排名 8

6 对决胜率预测 8

7 进攻线质量差异分析 9

7.1 方法 9

7.2 结果 9

8 提交可视化：阵容均衡 **vs.** 球队实力 9

9 完整分析仪表盘 10

10 ML 模型对比实验 11

11 描述性特征探索	12
11.1 门将表现 (GSAx)	12
11.2 射门质量 (xG/Shot)	12
11.3 纪律性 (PIM/G, 罚球差)	13
12 AI 协作	13
13 局限性与未来工作	13
14 结论	13

1 项目概述

1.1 竞赛背景

WHSDSC（沃顿高中数据科学竞赛）2026 第一阶段要求选手对 WHL 2025 赛季数据进行冰球数据分析，具体包含四项任务：

- (a) 实力排名与胜率预测：对全部 32 支球队进行实力排名，并预测 16 场第一轮对决的胜负概率。
- (b) 进攻线质量差异：找出一线与二线进攻线实力差距最大的前 10 支球队。
- (c) 可视化：用一张 PNG 回答：“阵容均衡的球队是否更强？”
- (d) 方法论报告：记录完整的分析过程。

1.2 核心思路

我们使用加时赛感知的 **Bradley-Terry** 配对比较模型估计球队潜在实力参数，然后通过校准逻辑回归将实力差转化为胜率预测——5 折交叉验证 Brier 分数达到 **0.2410**（基线 0.2465）。

2 数据处理流程

2.1 原始数据概况

数据集 `whl_2025.csv` 包含 **25,827** 条逐行对战记录，覆盖 **1,312** 场比赛、**32** 支球队。每行记录了一场比赛中某一对进攻线/防守组之间的对抗片段：

- 球队、进球数、期望进球 (xG)、射门数
- 进攻线编号（如 `first_off`、`second_off`）
- 防守组编号（如 `first_def`、`second_def`）
- 上冰时间 (TOI, 单位：秒)、罚时分钟、门将姓名
- 是否进入加时赛 (`went_ot`)

数据均衡：每支球队恰好进行了 82 场比赛（41 主场 + 41 客场）。

2.2 处理流程图

图 1 展示了从原始数据到最终输出的完整流水线。




Figure 1: 端到端流水线：逐行数据分为两条主线（实力估计与胜率预测、进攻线差异分析），并生成综合实力排名。

2.3 关键预处理步骤

1. **比赛级汇总**：将每场比赛的进球、xG、射门、TOI、罚时按球队求和，提取二元结果（主队胜 = 1，客队胜 = 0）。
2. **平局验证**：确认数据中不存在平局（所有比赛在常规时间或加时赛中都决出了胜负）。流水线若检测到平局会自动报错。
3. **TOI 单位校验**：原始 `toi` 字段单位为秒（每场比赛 TOI 总和中位数 = 3600.00，即 60 分钟）。所有“每 60 分钟”速率计算均除以 3600 而非 60。
4. **加时赛标记**：1,312 场比赛中有 288 场（22.0%）进入了加时赛，这些比赛在 Bradley-Terry 模型中接受特殊处理（见第 3 节）。

2.4 特征工程

我们将每场比赛的主客场记录对称堆叠（每场比赛出现两次，每队一次），计算以下团队级指标：

Table 1: 构造特征及其定义

特征	公式	含义
xGD/60	$\frac{xG_{\text{己}} - xG_{\text{对}}}{\text{TOI}/3600}$	每 60 分钟期望净胜球
xG 份额	$\frac{xG_{\text{己}}}{xG_{\text{己}} + xG_{\text{对}}}$	己方 xG 占比
PDO	射门命中率 + 扑救率	运气/可持续性指标
GSAx/G	$\frac{xGA - GA}{\text{场次}}$	预期失球以上扑救数（门将质量）
xG/射门	$\frac{xG_{\text{己}}}{\text{射门}_{\text{己}}}$	进攻射门质量
PIM/G	$\frac{\text{罚时分钟数}}{\text{场次}}$	球队纪律性
SOS	$\frac{1}{N} \sum_k \beta_{\text{对手}_k}$	赛程强度（对手 BT 均值）

3 核心模型：加时赛感知 Bradley-Terry

3.1 为什么选择 Bradley-Terry?

Bradley-Terry (BT) 模型 (Bradley & Terry, 1952) 是估计配对比较中潜在实力的标准模型。每支球队 i 拥有一个潜在实力参数 β_i ，球队 i 击败球队 j 的概率为：

$$P(i \text{ 胜 } j) = \sigma(\beta_i - \beta_j) = \frac{e^{\beta_i - \beta_j}}{1 + e^{\beta_i - \beta_j}} \quad (1)$$

其中 $\sigma(\cdot)$ 是 **logistic (sigmoid)** 函数：

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

关键性质：

- 若 $\beta_i > \beta_j$ ，则 $P(i > j) > 0.5$ ——实力更强的球队被预测为优势方。
- 该模型具有传递性：它隐式地控制了对手强度。
- 参数在常数平移下不可识别，我们令 $\bar{\beta} = 0$ 。

3.2 加时赛问题

图 2 展示了一个关键发现：主场优势在加时赛中几乎消失。




Figure 2: 常规时间主场胜率 57.6% ($n = 1024$) vs. 加时赛 52.1% ($n = 288$)。加时赛结果接近“掷硬币”，其中包含的球队实力信号远弱于常规时间胜负。

如果一场比赛进入加时赛，说明两队在 60 分钟常规时间内旗鼓相当。加时赛胜者很大程度上由运气决定（3 对 3 突然死亡或点球大战）。如果将加时赛胜利与 5-1 常规时间大胜等同对待，会向 **BT** 估计注入噪声。

我们的解决方案：在似然函数中对加时赛赋予 $w = 0.5$ 的权重：

$$\ell(\beta) = \sum_{k=1}^K w_k \left[y_k \log \sigma(\beta_{h_k} - \beta_{a_k}) + (1 - y_k) \log(1 - \sigma(\beta_{h_k} - \beta_{a_k})) \right] \quad (2)$$

其中： $w_k = 0.5$ （加时赛）或 1.0 （常规时间）； $y_k = 1$ 表示主队获胜； h_k, a_k 分别为主/客队索引。

3.3 迭代最大似然算法

我们使用对角 Newton 法最大化对数似然 (2)：

Algorithm 1: 加时赛感知 Bradley-Terry 迭代 MLE 算法

Input: 比赛结果 $\{(h_k, a_k, y_k, w_k)\}_{k=1}^K$ ，球队集合 $\{1, \dots, N\}$
Output: 实力向量 $\beta \in \mathbb{R}^N$

```

1  $\beta \leftarrow \mathbf{0}$ ;
2 for  $iter = 1$  to 300 do
3    $\mathbf{g} \leftarrow \mathbf{0}$ ,  $\mathbf{H}_{\text{diag}} \leftarrow \mathbf{0}$ ;                                     // 梯度与 Hessian 对角线
4   foreach 比赛  $k$ : 主队  $h_k$  vs 客队  $a_k$  do
5      $p \leftarrow \sigma(\beta_{h_k} - \beta_{a_k})$ ;                                     // 预测概率
6      $\text{residual} \leftarrow w_k(y_k - p)$ ;
7      $\text{fisher} \leftarrow w_k \cdot p(1 - p)$ ;
8      $g_{h_k} \leftarrow g_{h_k} + \text{residual}$ ;  $g_{a_k} \leftarrow g_{a_k} - \text{residual}$ ;
9      $H_{h_k} \leftarrow H_{h_k} - \text{fisher}$ ;  $H_{a_k} \leftarrow H_{a_k} - \text{fisher}$ ;
10  end
11   $\delta \leftarrow -\mathbf{g} / \mathbf{H}_{\text{diag}}$ ;                                     // Newton 步长（逐元素）
12   $\delta \leftarrow \delta - \bar{\delta}$ ;                                     // 中心化：保持  $\sum \beta_i = 0$ 
13   $\beta \leftarrow \beta + 0.5 \cdot \delta$ ;                                     // 阻尼更新 ( $\nu = 0.5$ )
14  if  $\max(|\delta|) < 10^{-8}$  then 收敛退出;
15 end
16  $\beta \leftarrow \beta - \bar{\beta}$ ;                                     // 最终中心化
17 return  $\beta$ 

```

收敛性：算法通常在约 30 次迭代内收敛（远低于 300 次上限）。阻尼因子 $\nu = 0.5$ 防止过冲。

4 胜率预测：校准逻辑回归

4.1 模型公式

原始 BT 概率（公式 1）可能存在校准偏差，因为 BT 模型没有主场优势截距项。我们通过逻辑回归添加校准层：

$$P(\text{主队胜}) = \sigma(\alpha + \gamma \cdot (\beta_{\text{主}} - \beta_{\text{客}})) \quad (3)$$

- α = 截距，捕获主场优势（ $\alpha = 0.2724 \Rightarrow \sigma(0.2724) = 56.8\%$ ）
- γ = 缩放系数（ $\gamma = 0.9350$ ）

参数通过 Nelder-Mead 最小化负对数似然求解，预测值裁剪至 $[0.01, 0.99]$ 以防极端概率导致 log-loss 爆炸。

4.2 5 折交叉验证方案

为了诚实评估预测性能，我们使用 5 折 CV，其中一个关键细节是：每折中 **BT** 实力参数从零重新估计，仅使用训练数据。




Figure 3: 5 折交叉验证示意图：每折均在训练集上重新拟合 BT 与逻辑回归，确保零数据泄漏。

4.3 评估结果

Table 2: 模型对比：5 折交叉验证结果

模型	准确率	Log-Loss	Brier 分数
基线（主队胜率 = 56.4%）	56.4%	0.6861	0.2465
加时赛感知 BT 逻辑回归	58.1% ± 3.2%	0.6752	0.2410

指标解读：

- **准确率（58.1%）**：相比“永远预测主队胜”的基线（56.4%）提升不大。这符合预期——冰球是四大职业联赛中随机性最高的运动，专业模型准确率也仅在 58–62% 之间。
- **Log-Loss（0.6752）**：衡量概率预测的置信度质量。越低越好。
- **Brier 分数（0.2410）**：概率预测的均方误差。相比基线降低 2.2%，在高随机性运动中已是有意义的提升。

4.4 概率校准

校准衡量预测概率与实际结果的一致性。我们使用折外 (**OOF**) 预测计算校准分箱，防止乐观偏差。

Table 3: 折外预测校准表。校准良好的模型应满足“预测 $\approx$ 观测”。

分箱中心	平均预测值	实际胜率	样本量 N
0.34	0.351	0.390	77
0.42	0.430	0.512	207
0.51	0.512	0.531	290
0.59	0.591	0.539	334
0.67	0.671	0.672	262
0.76	0.753	0.699	103

模型在 0.35–0.70 范围内校准良好。在高端（预测 0.75，实际 0.70）存在轻微过度自信，这是已知的局限性（见第 13 节）。

5 集成实力排名

5.1 综合评分构造

我们使用五项指标的加权 z -score 集成进行排名：

$$\text{综合分}_i = \sum_{m=1}^5 w_m \cdot z_{i,m}, \quad z_{i,m} = \frac{x_{i,m} - \bar{x}_m}{\sigma_m} \quad (4)$$

Table 4: 集成权重分配及理由

指标	权重	理由
BT 实力值	40%	核心潜在质量度量，自动控制对手强度
xGD/60	30%	过程导向指标，比实际进球更稳定
xG 份额	10%	相对进攻优势
净胜球/场	10%	已实现结果（非仅期望值）
胜率	10%	竞技结果的直接衡量

5.2 权重鲁棒性

我们测试了四种备选权重方案：BT 独占（100%）、均等（各 20%）、xG 倾斜（xGD/60 占 50%）。所有方案之间的 Spearman 秩相关系数为 **0.90–0.99**。前 6 名球队在所有方案中保持一致，证明排名对权重选择具有鲁棒性。

5.3 Top 10 排名

Table 5: 实力排名（32 队中前 10 名）。完整排名见 CSV 提交文件。

#	球队	综合分	BT	xGD/60	xG%	胜率	GSAx/G	SOS
1	Brazil	2.073	0.940	0.599	.551	.707	+0.40	−0.050
2	Thailand	1.612	0.484	0.865	.571	.610	−0.32	−0.029
3	Netherlands	1.535	0.641	0.472	.546	.659	+0.34	−0.028
4	Pakistan	1.296	0.424	0.611	.549	.598	+0.26	−0.026
5	Peru	1.273	0.532	0.340	.532	.634	+0.45	−0.020
6	China	0.915	0.282	0.411	.537	.573	+0.34	−0.010
7	Panama	0.653	0.267	0.190	.516	.561	+0.35	−0.017
8	India	0.633	0.396	0.016	.501	.598	+0.55	−0.027
9	UK	0.453	−0.012	0.424	.535	.476	+0.35	+0.006
10	Guatemala	0.292	0.021	0.270	.523	.512	−0.04	−0.002

关键洞察：

- **Brazil:** 以最高 BT 实力值（0.940）和胜率（70.7%）独占鳌头。
- **Thailand:** 凭借联盟最佳 xGD/60（0.865）位居第二，但 GSAx 为负（门将偏弱）。
- **India**（第 8）：拥有最佳 GSAx/G（+0.55）但 xGD 平平，说明强大门将掩盖了较弱的进攻。

6 对决胜率预测

使用校准逻辑回归模型（公式 3），我们预测第一轮 16 场对决：

Table 6: 第一轮对决预测。所有 16 场比赛均预测主队获胜（主场优势效应）。

场次	主队	客队	主队胜率	置信度
1	Brazil	Kazakhstan	85.2%	高
2	Netherlands	Mongolia	81.6%	高
3	Peru	Rwanda	79.4%	高
4	Thailand	Oman	73.3%	中
5	Pakistan	Germany	71.2%	中
6	India	USA	72.1%	中
7	Panama	Switzerland	68.8%	中
8	Iceland	Canada	67.4%	中
9	China	France	66.9%	中
10	Philippines	Morocco	64.5%	低
11	Ethiopia	Saudi Arabia	64.0%	低
12	Singapore	New Zealand	59.1%	低
13	Guatemala	South Korea	59.7%	低
14	UK	Mexico	60.5%	低
15	Vietnam	Serbia	54.1%	五五开
16	Indonesia	UAE	63.3%	低

置信度分级：高（>75%）、中（65–75%）、低（55–65%）、五五开（<55%）。

7 进攻线质量差异分析

7.1 方法

我们用一线与二线每 60 分钟 xG 的比值衡量进攻线质量差异：

$$\text{差异比} = \frac{\text{xG}/60_{\text{一线}}}{\text{xG}/60_{\text{二线}}} \quad (5)$$

比值为 1.0 表示完全均衡；> 1.0 表示球队过度依赖一线。

关键校正：原始 xG/60 受防守对位质量的混杂影响。面对精英防守组的一线自然会产出更少的 xG。我们通过防守难度因子进行归一化：

$$\text{校正 xG}/60_{\text{线}} = \frac{\text{原始 xG}/60_{\text{线}}}{\text{防守难度因子}_{\text{对位防守组}}} \quad (6)$$

其中防守难度因子 = 该防守组的 xGA/60 与联盟平均值之比。

数据过滤：仅保留均势对抗（1/2 线进攻 vs. 1/2 对防守组），排除强打、少打和空门时段。

7.2 结果

Table 7: 校正后进攻线差异排名前 10

#	球队	一线校正 xG/60	二线校正 xG/60	校正比值
1	USA	2.730	1.993	1.369
2	Guatemala	2.821	2.070	1.363
3	Saudi Arabia	2.244	1.654	1.357
4	UAE	1.998	1.476	1.354
5	France	2.559	1.901	1.346
6	Iceland	2.589	1.961	1.321
7	Singapore	2.635	2.101	1.254
8	New Zealand	2.441	1.975	1.236
9	Peru	2.391	1.983	1.206
10	Panama	2.545	2.120	1.201

8 提交可视化：阵容均衡 vs. 球队实力

提交可视化（图 4）直接回答赛事专员的问题：“进攻阵容更均衡的球队是否表现更好？”




Figure 4: 校正进攻线差异 (x 轴) vs. 综合实力评分 (y 轴)。Pearson $r = -0.031$, $R^2 = 0.001$ 。结论：不存在显著线性关系——球队通过多样化的阵容策略取得成功。

设计选择：

- 色盲友好：viridis 色图（感知均匀，对色觉缺陷安全）。
- 标注：前 5 名和后 3 名球队加标签，便于快速识别。
- 统计叠加：线性趋势线、Pearson r 和 R^2 ，提供定量评估。

9 完整分析仪表盘

图 5 展示了完整的 5 面板分析仪表盘。




Figure 5: 完整分析仪表盘：（左上）阵容均衡 vs. 实力散点图，（右上）校准曲线，（左下）实力排名柱状图，（中下）第一轮对决预测，（右下）前 10 进攻线差异。

10 ML 模型对比实验

除了最终采用的 BT 逻辑回归外，我们还测试了多种机器学习挑战者模型作为基准比较。图 6 展示了完整的 ML 模型对比仪表盘。

WHSDSC 2026 — ML Model Comparison Dashboard




Figure 6: ML 模型对比仪表盘（6 面板）：（左上）5 折 CV 准确率对比——XGBoost 57.5% 最高，（中上）Brier 分数与 Log-Loss 对比，（右上）各模型校准曲线，（左下/中下）Elastic Net 与 XGBoost 特征重要性，（右下）汇总表。总体上复杂 ML 仅带来边际提升，且可能牺牲校准；BT 仍是最重要的单一特征。

关键发现：

- 最佳准确率：XGBoost 达到 57.5%，但 Log-Loss 0.7154、Brier 0.2575，校准明显变差，不适合作为概率输出模型。
- 最佳概率质量：Elastic Net 逻辑回归在 Log-Loss（0.6774）与 Brier（0.2421）上最优，但准确率仅 57.0%，且引入多变量复杂性。
- 可解释性最强且竞争力足够：BT-only 逻辑回归（57.3%，Log-Loss 0.6814，Brier 0.2437）已接近最优；混合集成（56.9%）未带来稳定提升。
- XGBoost 和 Elastic Net 的特征重要性均显示 **BT** 是最重要的单一预测变量。
- 因此最终提交仍采用 **OT-aware BT** + 校准逻辑回归，优先考虑可解释性和稳定校准（见第 4 节）。

11 描述性特征探索

我们探索了数据集中三个未用于预测的额外特征：

11.1 门将表现 (GSAx)

预期失球以上扑救数 (GSAx/场) = (xGA - GA)/场次。正值表示门将扑出了超过预期的射门。GSAx 与 BT 实力的相关系数 $r = 0.64$ ——强队通常拥有强门将，因此将 GSAx 加入逻辑回归不增加任何准确率。

11.2 射门质量 (xG/Shot)

每次射门的平均期望进球衡量进攻质量。与 BT 的相关性 $r = 0.48$ 。在挑战者实验中加入该特征后，概率质量指标 (**Brier/Log-Loss**) 未见改善且可能略有恶化，因此仅作为描述性分析保留。

11.3 纪律性 (PIM/G, 罚球差)

通过每场罚时分钟数和罚球净值衡量球队纪律性。与 BT 的相关性 $r = 0.10$ (弱)。无预测提升。
结论：三个特征均被 **BT** 模型大量吸收——球队的胜负记录已经捕获了门将质量、射门质量和纪律性的下游效应。我们将其作为描述性列报告在排名 CSV 中，但不纳入预测模型，防止过拟合。

12 AI 协作

三个 AI 助手在项目中提供了独立视角：

Table 8: AI 协作分工

AI	贡献
Claude (Anthropic)	核心流水线设计、特征工程、BT 实现、深度验证 (22 项检查清单)
Gemini (Google)	审查排名、建议门将/特勤特征、校准评审
Codex (OpenAI, GPT-5.3)	ML 挑战者验证、Brier 分数报告、88K token 代码审查 (8.5/10 评分)

所有输出均经过跨模型交叉验证；最终方法论决策由人类主导。

13 局限性与未来工作

1. 球队实力静态假设：我们将球队实力视为赛季内恒定。现实中球队会因交易、伤病和势头而变化。时间衰减加权（如指数衰减）可以改善，但数据集未提供日期/场序信息。
2. 高端过度自信：校准显示预测概率超过 70% 时，实际偏乐观 5–13 个百分点（预测 0.75，实际 0.70）。折外保序回归 (isotonic calibration) 可缓解此问题。
3. 冰球的固有随机性：58.1% 的准确率上限在冰球中是正常的。冰球是四大职业联赛中单场得分最低的运动，使得单场预测存在根本性限制。
4. 无球员级建模：我们将球队视为整体。纳入球员级数据（如 WAR、Corsi）可提升精细度，但数据集未提供。
5. 主场优势假设统一：我们对所有球队使用单一主场参数 α 。实际中不同场馆的主场优势程度不同。

14 结论

我们构建了一个原则性强、透明且可复现的冰球分析框架：

- 加时赛感知 **Bradley-Terry** 模型：正确地将加时赛胜利视为较弱的信号。
- 校准逻辑回归：提供可解释的胜率预测，配合诚实的折外评估。
- 防守校正的进攻线差异指标：控制了对位混杂因素。
- 明确发现进攻线均衡度与球队成功之间不存在显著关系 ($r = -0.031$)。

该模型优先考虑可解释性而非边际精度提升：领域专家可以审查从原始数据到最终预测的每一个步骤。这种透明性是本方案最大的优势。